

Pravd.prostor  $(\Omega, \mathcal{F}, P)$ ,  $\Omega \neq \emptyset, \mathcal{F} \subseteq P(\Omega), P : \mathcal{F} \rightarrow [0, 1]$ .  $P : \mathcal{F} \rightarrow [0, 1]; P(\Omega) = 1, P(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$  pro  $A_1, A_2, \dots$  po dvou disj.

$(\Omega, \mathcal{F}, P) : (1)P(A) + P(A^C) = 1 (2)A \subseteq B \implies P(A) \leq P(B) (3)P(A \cup B) = P(A) + P(B) - P(A \cap B) (4)P(A_1 \cup A_2 \cup \dots) \leq \sum P(A_i)$

Dk:(1) $\Omega = A \cup A^C \implies P(\Omega) = P(A) + P(A^C)$  (2) $B = A \cup (A - B); P(B) = P(A) + P(B - A) \implies \dots$  (3) $P(A \cup B) = P(A - B \cup A \cap B \cup B - A) + P(A \cap B) - P(A \cap B) = \dots$

(4)trik zdisjunk. $B_1 = A, B_2 = A_2 - A_1, B_i = A_i - \bigcup_{j=1}^{i-1} B_j : P(\bigcup A_i) = P(\bigcup B_i) = \sum P(B_i) = \sum P(A_i) \square$

O průnicích  $P(A_1 \cap \dots \cap A_n) = P(A_1)P(A_2|A_1) \dots P(A_n|A_1 \cap \dots \cap A_{n-1})$  Dk :  $P(A_1) \frac{P(A_1 \cap A_2)}{P(A_1)} \dots \frac{P(A_1 \cap \dots \cap A_n)}{P(A_1 \cap \dots \cap A_{n-1})} = P(A_1 \cap \dots \cap A_n) \square$

Úplná pravd.  $P(A) = \sum P(B_i)P(A|B_i). A, B_i \in \mathcal{F}, B_i$  rozklad A. Pokud  $P(B_i) = 0, = 0. Dk : P(A) = \sum P(A \cap B_i) = \sum P(A)P(A|B_i)$

Bayes  $P(B|A) = \frac{P(A|B)P(B)}{P(A)}$  Dk : triv. (jmenovatel podle ^) Df: Nezávislost  $P(A \cap B) = P(A)P(B) \quad P(\bigcap_{j \in I' \subseteq I} A_j) = \prod_{j \in I'} P(A_j)$

Df: Náhodná dis. vel.  $X : \Omega \rightarrow \mathbb{R}, Im(X)$  je spočetná . $\forall x \in \mathbb{R} : \{\omega \in \Omega : X(\omega) = x\} \in \mathcal{F}$  Df: Pravd.fce:  $p_X(x_i) = P(X = x_i) : \mathbb{R} \rightarrow [0, 1]$

Df:  $\mathbb{E}(X) = \sum_{x \in Im(X)} x p_X(x)$  pokud má souč. smysl. Pozn.:  $\mathbb{E}(X) = \sum_{\omega \in \Omega} X(\omega)P(\omega)$  Dk :  $\sum_{x \in Im(X)} \sum_{\omega: X(\omega)=x} X(\omega)P(\{\omega\}) = \dots$

LOTUS:  $\mathbb{E}(g(x)) = \sum_{x \in Im(X)} g(x)P(X = x)$  Dk :  $\mathbb{E}(Y) = \sum_{y \in Im(y)} y P(Y = y) : \{\omega : g(X(\omega)) = y\} = \bigcup_{x \in Im(X)} \{\omega : X(\omega) = x\}$

(disj. sjed.) : ... =  $\sum_{y \in Im(y)} y \sum_{x \in Im(X)} P(X = x). (Nyní(y = g(x))) \square$  Vlastnosti  $\mathbb{E} : (1)P(X \geq 0) = 1 \& \mathbb{E}(X) = 0 \implies P(X = 0) = 1$

(2) $\mathbb{E}(X) \geq c \implies P(X \geq c) > 0$  (3) $\mathbb{E}(ax + b) = a\mathbb{E}(X) + b$  (4) $\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y)$  Dk: (3) $g(x) = ax + b (+LOTUS + linearita)$

(4)pouze pro disk.pr.: linearita:  $= \sum_{\omega \in \Omega} (X(\omega) + Y(\omega))P(\omega)$  (1) $\mathbb{E}(X) = \sum_{x \in Im(X)} x(P(x) = 0 \implies xP(X = x) = 0 \implies x = 0 \vee P(X = x) = 0.$

(2)Sporem :  $c \leq \mathbb{E}(X) = \sum xP(X = x). P(X \geq c) = 0 \implies \forall x \geq c : P(X = x) = 0 \implies \sum xP(X = x) < \sum cP(X = x) = c \sum P(X = x) = c \implies c < c \implies$  spor

Df: Podm.  $\mathbb{E}: \mathbb{E}(X|B) = \sum_{x \in Im(X)} xP(X = x|B) 0$  celkové  $\mathbb{E} : B_1, \dots$  rozklad  $\Omega, X$  d.n.v.:  $\mathbb{E} = \sum P(B_i)\mathbb{E}(X|B_i)Dk : \mathbb{E}(X) = \sum xP(X = x) = \sum_x x \sum_i P(B_i)P(X = x|B_i) = \sum_i xP(B_i)P(X = x|B_i) = \sum_i P(B_i)\mathbb{E}(X = x|B_i) \square$

Df:  $var(X) = \mathbb{E}[(X - \mathbb{E})^2]. \sigma_X = \sqrt{var(X)}$  směr. odch.  $var(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2$  Dk :  $\mu = \mathbb{E}(X); \mathbb{E}[(X - \mu)^2] = \mathbb{E}[X^2 - 2X\mu + \mu^2] = ...linearita. \square$

$\mathbb{E}(X) = \sum_{n=0}^{\infty} P(X > n)$  když  $Im(X) \subseteq \mathbb{N}_0$  Df. Sdružená pstní fce vel X,Y:  $P_{X,Y}(x,y) = P(X = x \& Y = y) : \mathbb{R}^2 \rightarrow [0, 1]$ , pro  $\in \mathcal{F}$

$var(aX + b) = a^2 var(X)$  Df: Nez. náh. vel:  $\forall x, y \{X = x\}, Y = y$  jsou nezav. Df. Multinomiální rozd.  $P_{X_1, \dots, X_n}(k_1, \dots, k_n) = \binom{n}{k_1, \dots, k_n} p_1^{k_1} \dots p_n^{k_n}$

Konvoluce  $P(X + Y = z) = \sum_{x \in Im(X)} P(X = x \& Y = z - x) = \sum_{x \in Im(X)} p_X(x)p_Y(z - x).$   $\mathbb{E}(g(X, Y)) = \sum_{x \in Im(X), y \in Im(Y)} g(x, y)P_{X,Y}(x, y)$

(< máli součet smysl.). Dk:  $P(Z - z) = \sum_{x \in Im(X)} P(X = x)P(Z - z|X = x)$ . Dle df Z:  $P(Z - z|X = x) - P(Y - z - x|X = x)P(Y - z - x|X = x) -$

(nez.)= $P(Y = z - x) \square$  Pro n.n.v  $\mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y)$  Dk :  $\mathbb{E}(XY) = \sum_{x,y \in Im} (xy)P(X = x \& Y = y) = \sum xyP(X = x)P(Y = y) = \mathbb{E}(X)\mathbb{E}(Y) \square$

$var(X + Y) = var(X) + var(Y) + 2cov(X, Y)$  Df: kovariance  $cov(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y), cov(X, Y) = \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y)))$

$cov(X, Y) \leq \sqrt{var(X)var(Y)} \implies -\sigma_X\sigma_Y \leq cov(X, Y) \leq \sigma_X\sigma_Y$  Df: Korelace  $cor(X, Y) = \frac{cov(X, Y)}{\sigma_X\sigma_Y}$  Věta  $var(\sum_{i=1}^n X_i) = \sum_{i=1, j=1}^n cov(X_i, X_j) =$

$= \sum_{i=1}^n var(X_i) + \sum_{i \neq j} cov(X_i, X_j) = (\text{pro po 2 nezav.}) = \sum^n var(X_i)$  Dk:  $\mathbb{E}(\sum X_i)^2 = \mathbb{E}(\sum_{i,j} X_i X_j) = \sum_{i,j} \mathbb{E}(X_i X_j)$

$(\mathbb{E}(\sum X_i))^2 = \sum_{i,j} \mathbb{E}(X_i)\mathbb{E}(X_j) \implies var(\sum X_i) = \mathbb{E}(\sum X_i)^2 - (\mathbb{E}(\sum X_i))^2 = \sum_{i,j} \mathbb{E}(X_i X_j) - \mathbb{E}(X_i)\mathbb{E}(X_j) = \sum_{i,j} cov(X_i, X_j) (1. =)$

$cov(X, X) = var(X) (\text{ze vzorce}) (2. =) NEZ \implies cov(X_i, X_j) = 0 (3. =) \square$   $P_{X|A}(x) = P(X = x|A); P_{X|Y}(x|y) = P(X = x|Y = y)$

Df. Obecná n.v.  $X : \Omega \rightarrow \mathbb{R}; \forall x \in \mathbb{R} : \omega \in \Omega : X(\omega) \leq x \in \mathcal{F}$  Df.: Distribuční funkce  $F_X(x) = P(X \leq x)$ ; poz: neklesající, zprava spojité,  $\lim$

Df. X je spojité n.v.:  $\exists f_X : \mathbb{R} \rightarrow [0, \infty] : F_X(x) = \int_{-\infty}^x f_X(t)dt$  má hustotu. Věta: (1) $P(X = x) = 0 \forall x \in \mathbb{R}$  (2) $P(a \leq X \leq b) = \int_a^b f_X(t)dt$

(3) V rozumn. množ.  $A : P(X \in A) = \int_A f_X(t)dt$  Dk: (1), (3) bez dk (2) $P(a \leq X \leq b) = P(a < X \leq b) = P(X \leq b) - P(X \leq a) = \int_a^b f_X - \int_{-\infty}^a f_X = \int_a^b f_X \square$

Df:  $\mathbb{E}(X) = \int_{-\infty}^{\infty} xf_X(x)dx$  pokud má smysl. LOTUS2:  $\mathbb{E}(g(X)) = \int_{-\infty}^{\infty} g(x)f_X(x)dx$  Bez dk.

Df.: Kvantilová fce  $X$  n.v.,  $Q_X : [0, 1] \rightarrow \mathbb{R} : Q_X(p) = \min\{x \in \mathbb{R} : p \leq F_X(x)\}$  Pokud X je spoj. rostoucí:  $Q_X = F_X^{-1}$  Df.: medián  $Q_X(\frac{1}{2})$ , kvartil,

Veta: X n.v. s dist  $f_X = F'$ , F je spoj. rost.:  $F(X) \sim U(0, 1)$ . Dk:  $Y := F(X). F'_y(y) = P(Y \leq y) = P(F(X) \leq y) = (\text{pro } y = F(x)) = P(X \leq x)$

pro  $y \in (0, 1) \dots F(x) = y$ , pro  $y > 1 \dots 1$ , pro  $y < 0 \dots 0 \square$ . Veta: F je fce "typu dist. fce", Q je odp. kvant. fce,  $U \sim U(0, 1), X = Q(U)$ , pak  $F_X = F$

Dk:  $P(Q(U) \leq x) = P(U < F(x)) = F(x) \square$

Df: Náhod. Vektor (X,Y) na Pravd.prost. je dvojice n.v.:  $\forall x, y \in \mathbb{R}$  je def.  $F_{X,Y}(x, y) = P(X \leq x \& Y \leq y) (\in \mathcal{F})$  sdružená dist. fce. Df: pokud

$\forall x, y F_{X,Y}(x, y) = \int_{-\infty}^x \int_{-\infty}^y f_{X,Y}(s, t)dsdt$  tak X,Y jsou sdruženě spojité a  $f_{X,Y}$  je sdružená hustota. Nezávislost  $\iff \{X \leq x\}, \{Y \leq y\}$  nezav.

$F_{X,Y}(x, y) = F_X(x)F_Y(y) \iff f_{X,Y}(x, y) = f_X(x)f_Y(y)$ . Konvoluce: X,Y n.n.v spojité  $\Rightarrow Z = X + Y$  taky spojité,  $f_Z(z) = \int_{-\infty}^{\infty} f_X(x)f_Y(z - x)dx$

Normální rozd.  $\varphi(x) = 1/\sqrt{2\pi} \exp(-x^2/2)$ .  $\varphi_X(x) = \frac{1}{\sigma} \varphi(\frac{x-\mu}{\sigma})$ . Vícerozměrné normální rozd.  $\varphi(t) = \frac{1}{\sqrt{2\pi}} e^{-t^2/2}. f(t_1, \dots, t_n) = \varphi(t_1) \dots \varphi(t_n)$

$f(t_1, \dots, t_n) = (2\pi)^{n/2} \exp(-\frac{(t_1^2 + \dots + t_n^2)^2}{2})$ . Df. Podm. hustota:  $f_{X|Y}(x, y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}$  pokud  $f_Y(y) > 0$ . Marginální hust:  $f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x, y)dx$

Markovova nerovnost: X je n.v.  $X \geq 0, a > 0 : P(X \geq a) \leq \frac{\mathbb{E}(X)}{a}$  Dk:  $\mathbb{E}(X) = P(X \geq A)\mathbb{E}(X|X \geq a) + P(X < A)\mathbb{E}(X|X < a)$  (druhý větší než 0)

Čebyšev: X je nv.  $\mathbb{E}(X) = \mu < \infty, var(X) = \sigma^2 < \infty : P(|X - \mu| \geq a\sigma) \leq \frac{1}{a^2}$  Dk:  $Y = (X - \mu)^2 \geq 0. P(Y > a^2\sigma^2) \leq \frac{\mathbb{E}(Y)}{a^2\sigma^2} = \frac{var(X)}{a^2\sigma^2} \square$  (Markov.)

Chernoff  $X = \sum X_i. X_i$  n.n.v.  $= \pm 1(50\%), t > 0 : P(X \geq t) = P(X \leq -t) \leq \exp(-\frac{t^2}{2\sigma^2})$ . Kde  $\sigma = \sqrt{n}$  Bez dk.

Silný. zák. velk. č.:  $X_1, X_2, \dots$  Jsou stejně rozd. n.n.v s  $var = \sigma^2, \mathbb{E} = \mu. S_n = \frac{X_1 + \dots + X_n}{n}$ , (vyb. prům.) pak  $\lim_{n \rightarrow \infty} S_n = \mu$  skoro jistě ( $P = 1$ ).

Pozn: Důsl: je dobré opakovat mření. Aplik: Monte Carlo integrace. (konec dk. slabý)  $\implies P(|S_n - \mu| > \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2}. \lim_{n \rightarrow \infty} \frac{\sigma^2}{n\varepsilon^2} = 0 \square$

Slabý z.v.c: (stejně př. jako silný).  $\forall \varepsilon > 0 : \lim_{n \rightarrow \infty} P(|S_n - \mu| > \varepsilon) = 0$  Dk: (Čebyšev pro  $X = S_n, a = \sqrt{n\varepsilon}/\sigma$ )  $E(S_n) = \frac{\mathbb{E}(X_1) + \dots + \mathbb{E}(X_n)}{n} = \mu$

$var(S_n) = var(\frac{(X_1) + \dots + (X_n)}{n}) = \frac{var(X_1) + \dots + var(X_n)}{n^2} = \frac{\sigma^2}{n}$ . Čebyšev:  $P(|S_n - \mu| > \varepsilon) \leq \frac{1}{a^2} \implies P(|S_n - \mu| > a\frac{\sigma}{\sqrt{n}}) \leq \frac{1}{a^2}$  (konec ^)

Gambler's fallacy: if a particular event occurs more frequently than normal during the past, it is less likely to happen in the future(není limita)

CLV:  $X_1, X_2, \dots$  Jsou stejně rozd. n.n.v s  $var = \sigma^2, \mathbb{E} = \mu. Y_n = \frac{(X_1 + \dots + X_n) - n\mu}{\sigma\sqrt{n}}$ . Pak  $Y_n \xrightarrow{d} N(0, 1)$ . Neboli pokud  $F_n = F_{Y_n} : \forall x \in \mathbb{R} : \lim_{n \rightarrow \infty} F_n(x) = \Phi(x)$

Význam: umožnuje approximovat součet mnoha náhodných veličin pomocí jednoho, dobre známého rozdelerí. Takové součty se casto

vyskytují – např Bin(n; p) je součet n veličin Ber(p), ve statistice takové součty casto potkáme a mnoho fyzikálních jevu je (približně) popsáno jako součet nez náh vel. To vysvetluje, proc binomická císla, stejne jako mnoho v praxi se vyskytujících veličin, mají približně normální rozdelení

-Testování hypotez: Testujeme platnost tvrzení, např. mince spravedlivá. Označíme  $H_0$  očekávané, tzv. nulovou hypotézu. Alternativní

hypotéza  $H_1$ . Vytvoříme statistický model situace (pokud házíme n-krát minci, typicky jednotlivé hody jsou nezávislé, rozdelení  $Bin(n; \theta)$ ).  $H_0$  říká  $\theta = \frac{1}{2}$ . Před naměřením rozhodneme, jaký bude kritický obor, množina W možných měření, při kterých  $H_0$  zamítne. Chceme zajistit, aby

byla předem daná prvd. chybou 1. druhu: chyběného zamítnutí. Omezení pravděpodobnosti chybou 1. d. značíme  $\alpha$  Zároveň se snažíme min.

pravděpodobnost chybou 2. druhu, chyběného přijetí (značíme  $\beta$ ). Pravděpodobnost, že chyběnou hypotézu zamítne nazýváme síla testu.

-Test dobré shody: Opakujeme n-krát pokus, který muže dopadnout jedním z k výsledku, opakování jsou nezav. Testujeme nulovou hyp., že i-tý výsledek nastává s prvd.  $p_i$ . Pro  $i = 1, \dots, k$  označme  $X_i$  pocet pokusu s i-tým výsledkem a  $E_i = p_i n$  střední hodnotu  $X_i$ . Dále spociteme

Pearsonovu statistiku  $T = \sum_{i=1}^k \frac{(E_i - X_i)}{E_i}$  kritická hod.  $\gamma$  je kvantilová funkce  $\chi^2$  rozdelení s k-1 stupni volnosti v bode  $1 - \alpha$ , tj.  $\gamma = Q(1 - \alpha)$ ,

kde Q je kvant. funkce pro  $\chi^2_{k-1}$ .  $H_0$  zamítne, pokud  $T > \gamma$ . Pri takové volbe je pravděpodobnost chybou prvního druhu približně rovna  $\alpha$ .

-jak generovat náhodnou veličinu s danou dist. fci: Inverse transformation: Nechť F je funkce "typu distribucní funkce": neklesající zprava

spojují funkce s  $\lim_{x \rightarrow -\infty} F(x) = 0$  a  $\lim_{x \rightarrow \infty} F(x) = 1$ . Nechť Q je odpov. kvantilova. fce. Nechť  $U \sim U(0, 1), X = Q(U)$ . Pak X má dist. fci F.

Zamítací metoda: Chceme vygenerovat n.v. s hustotou f. Umíme vygenerovat n.v. s hustotou g, "podobná",  $\frac{f(y)}{g(y)} \leq c$  pro nějakou konst. c.

Postup: 1. vygenerujeme Y s hust. g, a  $U \sim U(0, 1)$ . 2. Pokud  $U \leq \frac{f(Y)}{g(Y)}$ , tak  $X := Y$ . 3. Jinak hodnotu Y, U zamítne a opakujeme od bodu 1.

-Empiricka dist.fce: Pro náh. výběr:  $X_1, \dots, X_n$ : e.d.f:  $\hat{F}_n(x) = \frac{\sum_{i=1}^n I(X_i \leq x)}{n}$ .  $I(X_i \leq x) = 1$  pokud  $X_i \leq x, 0$  jinak.

-Metoda max. věrohodnosti:  $X_1, \dots, X_n$  výběr,  $x_1, \dots, x_n$  realizace, diskrétní  $p_X(x, \vartheta) = \prod p_{X_i}(x_i, \vartheta)$ , spojité  $p_X(x, \vartheta) = \prod p_{X_i}(x_i, \vartheta)$  = Likelihood  $L(x, \vartheta)$ . Zvolíme takové  $\vartheta$ , aby  $L$  bylo maximální, případně stačí max.  $l = \log L$ . Př: Počítání leváků: k z n lidi jsou leváci:  $X_1, \dots, X_n \sim Bern(\vartheta)$   $L(x, \vartheta) = \vartheta^k(1-\vartheta)^{n-k}$ ,  $l = k \log \vartheta + (n-k) \log(1-\vartheta)$ . Najdeme maximum derivací. Př2: Kostka, 6=p=x, hodil 2,3,6.  $p^x(\frac{1-p}{5})^y$  minimalizujeme,  $\frac{1}{3}$

-Bodový odhad  $\hat{\Theta}_n$  pro nah. výb.  $X, \dots, X_n \sim F_\vartheta$  a libovolnou fci g je: Nevychýlený, pokud  $E(\hat{\Theta}_n) = g(\vartheta)$ . Asympt. Nevychýlený,

$\lim_{n \rightarrow \infty} E(\hat{\Theta}_n) = g(\vartheta)$  Konzistentní:  $(\hat{\Theta}_n) \xrightarrow{P} g(\vartheta)$ . Vychýlení bias( $\hat{\Theta}_n$ ) =  $E(\hat{\Theta}_n) - g(\vartheta)$ . Stred. kvad. odchyly.  $MSE(\hat{\Theta}_n) = E(((\hat{\Theta}_n) - g(\vartheta))^2)$ .

$\bar{X}_n = \frac{1}{n} \sum^n X_i$  výběrový průměr.  $\bar{S}_n^2 = \frac{1}{n} \sum^n (X_i - \bar{X}_n)^2$  výběrový rozptyl. - konz. asympt. nestran.  $\hat{S}_n^2 = \frac{1}{n-1} \sum^n (X_i - \bar{X}_n)^2$  rozptyl, konz. nestraný.

-Metoda momentů: r-tý moment pro  $X \sim F_\vartheta$  je  $m_r(\vartheta) = E(X_r^r)$ . rtý výběrový moment pro náh. výběr:  $\widehat{m_r}(\vartheta) = \frac{1}{n} \sum^n X_i^r$  je nestraný konz. odhad  $\widehat{m_r}(\vartheta)$  Tedy volíme \vartheta, řešící soustavu rovnic  $\widehat{m_r}(\vartheta) = m_r(\vartheta)$  pro 1...k - typicky  $k = \#\mathbb{R}$  císel tvořící parametr  $\vartheta$ . Př: náhodné výšky lidí  $\sim N(\mu, \sigma^2)$ ,  $\vartheta = (\mu, \sigma^2)$ .  $m_1(\mu) = \vartheta$ ,  $m_2(\mu) = E(X^2) = var(X) + E(X)^2 = \sigma^2 + \mu^2$ . Mame položit  $\mu = m_1(\vartheta) = \widehat{m_1}(\vartheta) = \bar{X}_n$ .  $\sigma^2 = m_2(\vartheta) = \widehat{m_2}(\vartheta) = \bar{X}_n^2 - \bar{X}_n^2/n$ . Řešení:  $\hat{\mu} = \bar{X}_n$ ,  $\hat{\sigma} = \sqrt{\frac{\bar{X}_n^2 - \bar{X}_n^2/n}{n-1}}$ . Př2: Kostka, pravd. padne 6=p, jinak rovnomerne. Padlo 2,3,6. Vypočteme  $E = 3 + 3p$  pak  $\hat{p} = \mu/3 - 1$

-Studentův t-test: Student. t-rozdelení s n-1 stupni volnosti  $\frac{\bar{X}_n - \mu}{\hat{S}_n/\sqrt{n}} = \Psi_{n-1}$ . Odhad. pro  $N(0,1)$  když nez. odch.  $\alpha \in (0, 1)$ :  $\Psi_{n-1}(t_{\alpha/2}) = 1 - \frac{\alpha}{2}$

$C_n = \langle \bar{X}_n - \delta; \bar{X}_n + \delta \rangle$  pro  $\delta = t_{\alpha/2} \frac{\hat{S}_n}{\sqrt{n}}$ . Pak  $P(\mu \in C_n) = 1 - \alpha$

-Jednovyberový test (z-test):  $X_1, \dots, X_n$  náhodný výběr,  $\sigma$  znamená ze zkusenosti  $H_0 = \mu$ . Zvolíme  $z_{\alpha/2} = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$  hranici, pak  $P(I. chyba) = \alpha$

-Dvouvyberový test:  $H_0 : \vartheta_X = \vartheta_Y$ , volíme  $z = \frac{\bar{X}_n - \bar{Y}_m}{\sigma\sqrt{1/n+1/m}}$ ,  $S = \bar{X}_n - \bar{Y}_m$ ,  $E(S) = 0$ . W stejně jako u 1-vyberového. Pokud neznamená rozptyl, použijeme vyberový rozptyl. P-hodnota: Říká, kolik % měření je horších. (the probability of obtaining test results at least as extreme as the result actually observed)

-Intervalové odhady:  $X_1, \dots, X_n$  náh. výb. z  $N(\vartheta, \sigma^2)$   $\alpha \in (0, 1)$ . Pak  $\Phi(z_{\alpha/2}) = 1 - \alpha/2$ ,  $S_n = (X_1 + \dots + X_n)/n$  (výběrový průměr)

$C_n = [\bar{X}_n - \delta'; \bar{X}_n + \delta']$ ,  $\delta' = z'_{\alpha/2} \frac{\hat{S}_n}{\sqrt{n}} = z'_{\alpha/2} \frac{\sqrt{\frac{1}{n-1} \sum \dots}}{\sqrt{n}}$  Pak  $P(\vartheta \in C_n) = 1 - \alpha$  Dk. Pomocí CLV.

-Lineární regrese: data:  $(x_i; y_i)$  pro  $i = 1 \dots n$ , cil:  $y = \vartheta_1 x + \vartheta_0$  meríme pomocí kvadratické odchylky  $\sum^n (y_i - (\vartheta_0 + \vartheta_1 x))^2$  - minimalizujeme.

-Permutační test: Máme k dispozici dve sady nezávislých náhodných velicin  $X_1 \dots X_n \sim F_X, Y_1 \dots Y_m \sim F_Y$ , chceme rozhodnout, zda platí  $H_0 : F_X = F_Y$ , nebo  $H_1 : F_X \neq F_Y$ . Např: doba behu programu pred/po vylepšení. Hladina cholesterolu u lidi, co jedí/nejedi pilulkou. Frekvence krátkých slov v textu autora X a Y. Nevíme nic o vlast.  $F_X, F_Y$ , nečekáme, že jsou norm. Postup: Zvolíme vhodnou statistiku např:  $T(X_1, \dots, X_n, Y_1, \dots, Y_m) = |\bar{X}_n - \bar{Y}_m|$ . Za predpokladu  $H_0$  jsou "sechny permutace stejné"  $X_i, X_j$  se generovaly ze stejného rozdělení.

$t_{obs} := T(X_1, \dots, X_n, Y_1, \dots, Y_m)$  Nahodne zpermutujeme zadanych m+n cisel a pro kazdou permutaci vycislime T, dostaneme  $T_1, T_2, \dots, T_{(n+m)!}$ . Jako p-hodnotu vzít pravd., ze  $T > t_{obs}$ . Neboli  $p = \frac{1}{(m+n)!} \sum_j I(T_j > t_{obs})$ . Tj pravd. I. chyby,  $H_0$  zamítne, pokud  $p < \alpha = 0.05$  (a zvolíme)

-Bootstrap: Z naměřených dat  $x_1, \dots, x_n \sim F$  vytvoříme  $\hat{F}_n$ . Další data můžeme samplovat z  $\hat{F}_n$ . To se dělá tak, že vybereme uniformně náhodne  $i \in \{1, \dots, n\}$  a řekneme  $x_i$ . Základní použití:  $T_n = g(X_1, \dots, X_n)$  nějaká statistika. Chceme odhadnout  $var(T_n)$ . Nasamplujeme  $X_1^*, \dots, X_n^* \sim \hat{F}_n$ . Spočteme  $T_n^* = g(X_1^*, \dots, X_n^*)$ . Opakujeme B-krát, dostaneme  $T_{n,1}^*, \dots, T_{n,B}^*$ . Odhad rozptylu:  $\frac{1}{B} \sum_{b=1}^B (T_{n,b}^* - \frac{1}{B} \sum_{k=1}^B T_{n,k}^*)^2$

-Bayesovská statistika: Srovnání: Frekventistický/klasický přístup: oPravděpodobnost je frekvence (z 6000 hodu kostkou padla šestka 1026-krát). Je to objektivní vlastnost reálného světa. oParametry jsou pevné, neznámé konstanty. Nelze o nich říkat smysluplné pravdepodobnostní výroky. oNavrhujeme statistické procedury tak, aby mely žádané dlouhodobé vlastnosti. Např. 95 % z našich intervalových odhadů pokryje neznámý parametr. |Vs. Bayesovský přístup: Pravd. popisuje, jak moc veríme nejakému jevu, jak moc jsme ochotní se vsadit.

(Pravdepodobnost, že Thomas Bayes m el 18. prosince 1760 šálek caje, je 90 %.) Mužeme vyslovovat pravdep. výroky i o parametrech (trebaže jsou to pevné konstanty). Spocítáme distribuci  $\vartheta$  a z ní tvoríme bodové a intervalové odhady, atd. Základní popis Bayes. metody: oneznámý parametr považujeme za náhodnou velicinu  $\Theta$ . ozvolíme apriorní distribuci (prior distribution), neboli hustotu pravdepodobnosti  $f_\Theta(\vartheta)$  nezávislou na datech. ozvolíme statistický model  $f_{\Theta|X}(\vartheta|x)$ , který popisuje, co nameríme (s jakou pravdepodobností), v závislosti na hodnote parametru opoté, co pozorujeme hodnotu  $X = x$ , spocítáme posteriorní distribuci (posterior distribution)  $f_{\Theta|X}(\vartheta|x)$  oz té pak odvodíme, co potrebujeme např najdeme a, b, aby  $\int_a^b f_{\Theta|X}(\vartheta|x)d\vartheta \geq 1 - \alpha$  | Bayesovské bodové odhady: MAP – Maximum A-Posteriori: Volíme  $\hat{\vartheta}$  tak, aby maximalizovalo  $p_{\Theta|X}(\vartheta|x)$  v diskrétním případě,  $f_{\Theta|X}(\vartheta|x)$  ve spojitém. LMS – Least Mean Square: Též metoda podmíněně střední hodnoty: Volíme  $\hat{\vartheta} = E(\Theta|X = x)$ . Př.: Bayes. klasifikátor spamu: 1.vytvoríme seznam podezřelých slov (money, win, pharmacy, ...) 2. N.v.  $X_i$  popisuje, zda email obsahuje podezřelé slovo  $w_i$ . 3. N.v.  $\Theta$  popisuje, zda email je spam  $\Theta = 1$  nebo ne  $\Theta = 0$ . 4. Z p'ecchozích email'ů u získáme odhady  $p_{X|\Theta}$  a  $p_\Theta$ . Použijeme Bayesovu vetu na výpočet  $p_{X|\Theta}$ .

$$\begin{aligned} cov(X, Y) &= E(XY) - E(X)E(Y) = E[(X - E(X))(Y - E(Y))] \\ var(x) &= E[(X - E(X))^2] = E(X^2) - E(X)^2 \\ var(aX + b) &= a^2 var(X) \\ var(X + Y) &= var(X) + var(Y) + 2cov(X, Y) \\ E(g(X)) &= \sum_{x \in Im(X)} g(x)P(X = x) \end{aligned}$$

$$\text{Pro } X, Y \text{ nezávislé: } E(XY) = E(X)E(Y)$$

$$\text{Cauchy } cov(X, Y) \leq \sqrt{var(X) \cdot var(Y)}$$

$$\text{neboli } -\sigma_X \cdot \sigma_Y \leq cov(X, Y) \leq \sigma_X \cdot \sigma_Y$$

Diskrétní rozdělení (P, E, var)

$$Bern(p), p_X(1) = p, p, p(p-1)$$

$$Binom(n, p), \binom{n}{k} p^k (1-p)^{n-k}, pn, pn(1-p)$$

$$Geom(p), p_X(x) = (1-p)^{x-1} p, \frac{1}{p}, \frac{1-p}{p^2}$$

$$Hypergeom(N, K, n), p_X(k) = \frac{\binom{N}{k} \binom{K}{n-k}}{\binom{N}{n}}, n \frac{K}{N}, -$$

$$Pois(\lambda), p_X(k) = e^{-\lambda} \frac{\lambda^k}{k!}, \lambda, \lambda \quad (\lim Binom(n, \frac{\lambda}{n}))$$

$$U(a, b), \frac{1}{b-a+1}, \frac{a+b}{2}, -$$

Odhad Bin pomocí Pois:  $Bin(n; p) \rightarrow Pois(np)$

Spojité rozdělení (f, F, E, var)

$$U(a, b), \frac{1}{b-a}, \frac{x-a}{b-a}, \frac{a+b}{2}, \frac{(b-a)^2}{12}$$

$$Exp(\lambda), \lambda e^{-\lambda x}, 1 - e^{-\lambda x}, \frac{1}{\lambda}, \frac{1}{\lambda^2}$$

$$N(\mu, \sigma^2), \frac{1}{\sigma} \varphi(\frac{x-\mu}{\sigma}) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}(\frac{x-\mu}{\sigma})^2}, \Phi(\frac{x-\mu}{\sigma}), \mu, \sigma^2$$

$$X_i \sim N(\mu_i, \sigma_i^2) \implies X_1 + \dots + X_n \sim N(\mu_1 + \dots + \mu_n, \sigma_1^2 + \dots + \sigma_n^2)$$

$$\Phi(-x) = 1 - \Phi(x)$$

x	0	1	2	3	4
$\Phi(x)$	0.5	0.84135	0.97725	0.99865	0.99997

$$Cauchy, \frac{1}{\pi(x+1)^2}, \frac{1}{\pi} \arctan x + \frac{1}{2}, \text{undef, undef}$$

Náhodné vektory

> Hustota a distribuční funkce

$$F_{X,Y}(x, y) = \int_{-\infty}^x \int_{-\infty}^y f_{X,Y}(s, t) dt ds$$

$$f_{X,Y}(x, y) = \frac{\partial^2 F_{X,Y}(x, y)}{\partial x \partial y}$$

> Marginální hustota

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dy$$

> Množiny

$$P((X, Y) \in A) = \int_A f_{X,Y}(x, y) dx dy$$

> Nezávislost XY

$$\Leftrightarrow f_{X,Y}(x, y) = f_X(x)f_Y(y) \Leftrightarrow F_{X,Y}(x, y) = F_X(x)F_Y(y)$$